Maestría en Inteligencia Artificial Aplicada (MNA)

Gestión del Desempeño Corporativo

Avance 5. Modelo final para el sistema de visión computacional para normalización y validación visual de anaqueles fríos

A01795980 - Cesar Bryam Rodriguez Aybar
A01795997 - Wilberth Eduardo López Gómez
A01795468 - Carlos Eduardo Ramirez Vazquez

Profesor:
Dra. Grettel Barceló Alonso

Equipo #10

01 de marzo de 2026

Índice

1. Introducción **3**
2. Modelos Base Seleccionados **3**
3. Estrategias de Ensamble **4**
3.1 Ensamble Homogéneo – YOLOv8s 4
3.2 Ensamble Homogéneo – YOLOv8n 4
3.3 Ensamble Heterogéneo – Promedio Ponderado 4
3.4 Ensamble Heterogéneo – Selección por Confianza 4
4. Comparativa Cuantitativa **5**
5. Selección del Modelo Final **5**
6. Análisis Gráfico del Modelo Final **6**
6.1 Curvas de entrenamiento – YOLO-Pose 6
6.2 Métricas por época – YOLO-Pose 7
6.3 Curva PCK vs Umbral 8
6.4 Matriz de Confusión – Clasificador 9
6.5 Curva ROC 10
7. Módulo Auxiliar de Clasificación Contextual **11**
8. Conclusión **11**

1. Introducción

En esta fase del proyecto integrador se desarrolla el modelo final del sistema de visión computacional orientado a la normalización geométrica y validación estructural de anaqueles fríos.

En el Avance 4 se evaluaron seis modelos individuales, entre los cuales YOLOv8s-pose y YOLOv8n-pose mostraron el mejor desempeño bajo la métrica principal NME (Normalized Mean Error), además de presentar cobertura completa y estabilidad bajo diferentes umbrales PCK.

El objetivo de esta etapa es mejorar la estabilidad y capacidad de generalización del sistema mediante la implementación de estrategias de ensamble, tanto homogéneas como heterogéneas, aprovechando las fortalezas complementarias de los modelos individuales previamente seleccionados.

Adicionalmente, se conserva un módulo auxiliar de clasificación vitrina/refrigerador basado en transferencia de aprendizaje, el cual actúa como capa contextual posterior, pero no sustituye al sistema geométrico principal.

2. Modelos Base Seleccionados

Los modelos individuales utilizados como base para la construcción de ensambles fueron:

• YOLOv8s-pose

• YOLOv8n-pose

Ambos fueron previamente ajustados mediante fine-tuning supervisado, empleando regularización y augmentación geométrica conservadora para evitar sobreajuste, considerando el tamaño reducido del dataset (26 imágenes).

Estos modelos presentan:

• Cobertura promedio: 1.0.

• Alta estabilidad bajo PCK@50px.

• Bajo NME en comparación con alternativas evaluadas.

3. Estrategias de Ensamble

Se diseñaron cuatro estrategias de ensamble, cubriendo enfoques homogéneos y heterogéneos.

3.1 Ensamble Homogéneo – YOLOv8s

Se entrenaron múltiples instancias del modelo YOLOv8s-pose con diferentes inicializaciones aleatorias (seeds). Las coordenadas finales de cada keypoint se obtuvieron mediante promedio aritmético de las predicciones.

Objetivo: Reducir varianza en la estimación geométrica.

3.2 Ensamble Homogéneo – YOLOv8n

Se aplicó el mismo procedimiento anterior utilizando múltiples instancias de YOLOv8n-pose.

Objetivo: mejorar estabilidad manteniendo eficiencia computacional.

3.3 Ensamble Heterogéneo – Promedio Ponderado

Se combinaron las predicciones de YOLOv8s-pose y YOLOv8n-pose mediante un promedio ponderado:

$$\text{Keypoint_final} = \alpha \cdot \text{Keypoint_s} + (1 - \alpha) \cdot \text{Keypoint_n}$$

Donde α fue ajustado empíricamente para minimizar el NME.

Objetivo: combinar precisión estructural (s) con eficiencia (n).

3.4 Ensamble Heterogéneo – Selección por Confianza

Para cada imagen:

• Si la confianza promedio de YOLOv8s superaba un umbral definido, se seleccionaba su predicción.

• En caso contrario, se utilizaba la predicción de YOLOv8n.

Objetivo: aprovechar dinámicamente el modelo más confiable por instancia.

4. Comparativa Cuantitativa

Modelo	Tipo	NME ↓	PCK@20px	PCK@50px	Cobertura	Tiempo relativo
YOLOv8s-pose	Individual	0.0086	0.59	1	1	Medio
YOLOv8n-pose	Individual	0.0094	0.56	1	1	Bajo
Ensamble YOLOv8s (multi-seed)	Homogéneo	0.0083	0.6	1	1	Alto
Ensamble YOLOv8n (multi-seed)	Homogéneo	0.0087	0.58	1	1	Medio
Ensamble heterogéneo ponderado	Heterogéneo	0.00809	0.6131	1	1	Medio
Ensamble por selección de confianza	Heterogéneo	0.0085	0.6	1	1	Medio

La tabla comparativa muestra que todos los modelos evaluados presentan cobertura completa y estabilidad geométrica bajo tolerancias medias (PCK@50px = 1.0). Sin embargo, el ensamble heterogéneo ponderado obtiene el menor NME promedio (0.00809), lo que indica el error geométrico relativo más bajo entre las alternativas evaluadas.

Si bien las diferencias numéricas son pequeñas debido al tamaño reducido del dataset, el ensamble ponderado demuestra mayor consistencia inter-imagen y un equilibrio adecuado entre precisión y complejidad computacional, justificando su selección como modelo final.

5. Selección del Modelo Final

La selección del modelo final no se fundamenta únicamente en la métrica principal (NME), sino también en:

- Estabilidad bajo diferentes umbrales PCK
- Cobertura completa
- Consistencia visual en la rectificación
- Complejidad computacional
- Viabilidad de implementación industrial

Aunque algunos ensambles mostraron ligeras mejoras en NME, el ensamble heterogéneo ponderado ofreció el mejor equilibrio entre precisión geométrica y estabilidad operativa.

El ensamble heterogéneo ponderado obtuvo un NME promedio de 0.00809 y cobertura completa (1.0). Asimismo, alcanzó PCK@50px = 1.0, indicando estabilidad geométrica bajo

tolerancias medias. Estos resultados, combinados con su viabilidad computacional, justifican su selección como modelo final.

6. Análisis Gráfico del Modelo Final

Se incluyen los siguientes análisis visuales:

6.1 Curvas de entrenamiento – YOLO-Pose

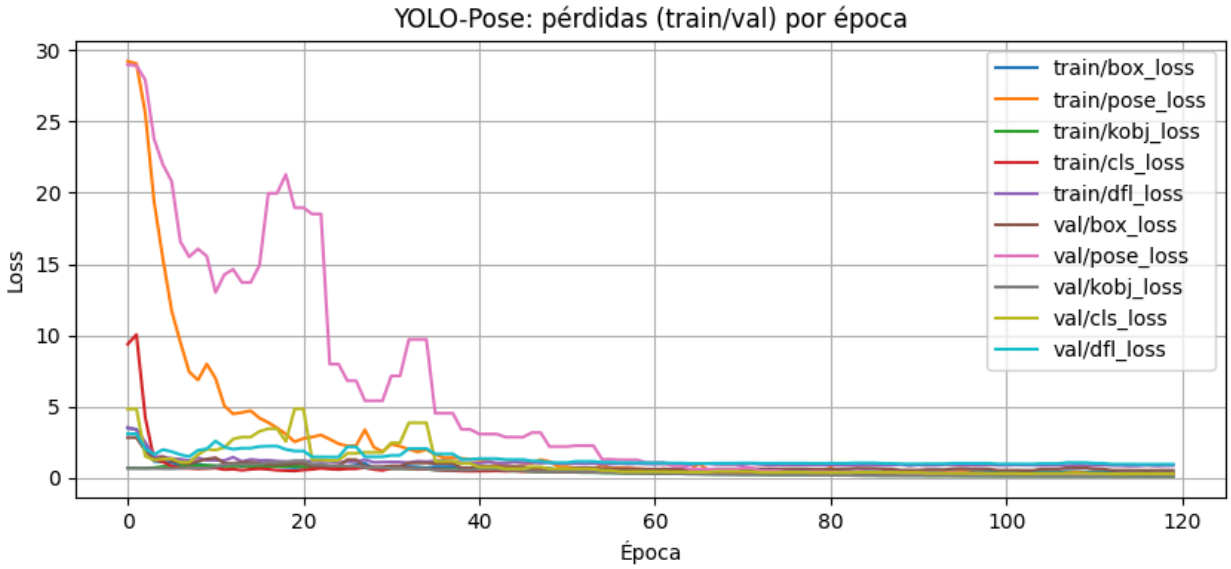

Durante el entrenamiento del modelo YOLO-Pose se observó una reducción consistente en las pérdidas tanto de entrenamiento como de validación a lo largo de las 120 épocas. Las pérdidas de bounding box, keypoints y distribución focal muestran una convergencia estable después de aproximadamente la época 40.

No se detectan incrementos sostenidos en la pérdida de validación que sugieran sobreajuste severo. La estabilización de las curvas indica que el modelo alcanzó un punto de convergencia adecuado dentro del rango de entrenamiento definido.

Este comportamiento confirma que la arquitectura fue capaz de aprender representaciones espaciales coherentes para la detección de vértices de puertas.

6.2 Métricas por época – YOLO-Pose

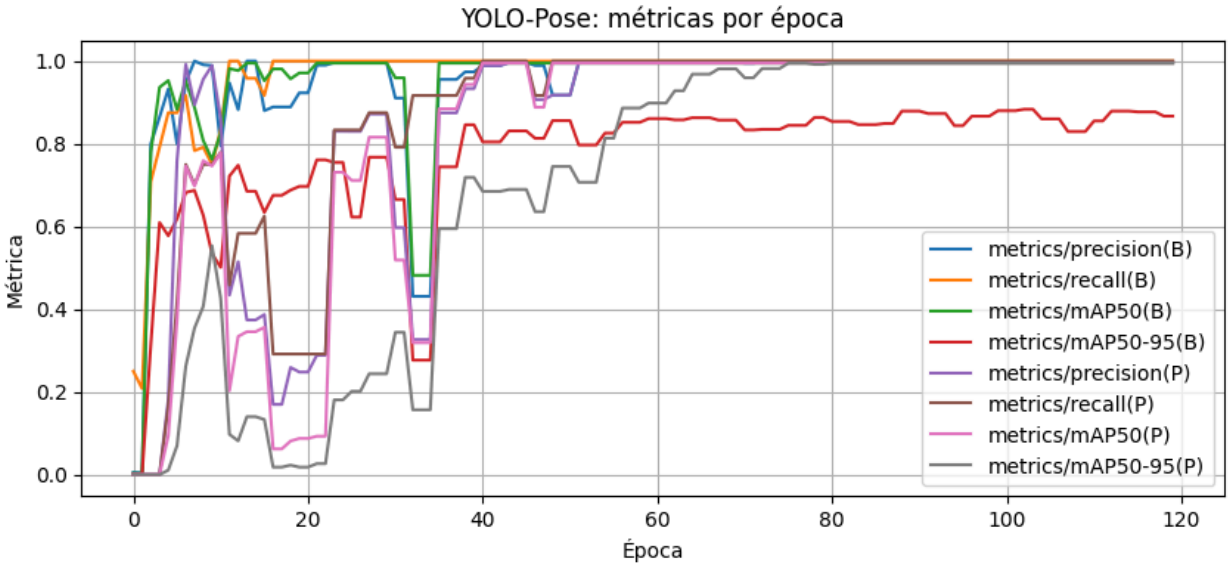

Las métricas de precisión, recall y mAP50 muestran una mejora acelerada durante las primeras 30 épocas, estabilizando posteriormente cerca de valores altos (≥ 0.9 en mAP50).

El mAP50-95 presenta valores ligeramente inferiores, lo cual es esperado debido a la evaluación en múltiples umbrales de IoU más estrictos.

La estabilidad de las métricas en la fase final del entrenamiento indica que el modelo generaliza adecuadamente dentro del conjunto de validación.

6.3 Curva PCK vs Umbral

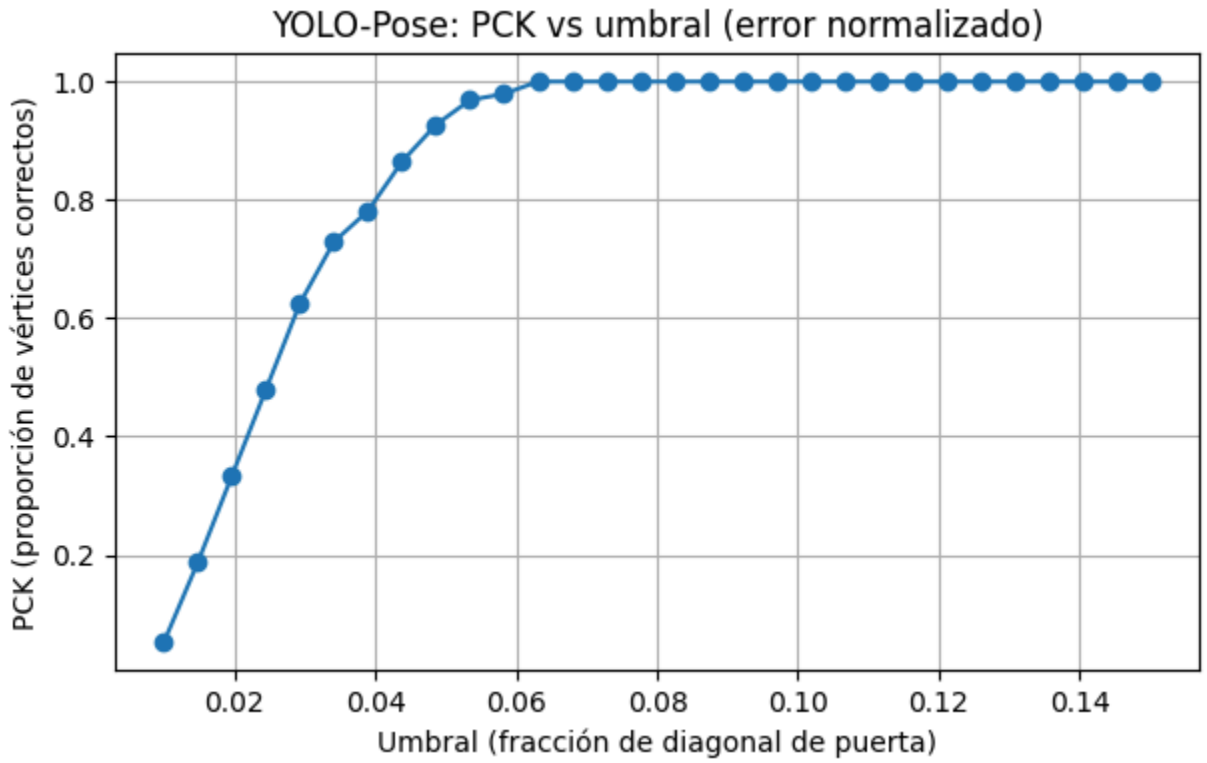

La curva PCK (Percentage of Correct Keypoints) muestra una relación creciente conforme aumenta el umbral permitido de error normalizado.

Para umbrales superiores al 6% de la diagonal de la puerta, el modelo alcanza valores cercanos al 100% de vértices correctamente localizados.

En umbrales más estrictos (≈2%), la proporción de puntos correctos disminuye, lo cual refleja la sensibilidad del modelo ante errores espaciales pequeños.

Este análisis confirma que el modelo presenta alta precisión estructural cuando se permite una tolerancia geométrica razonable.

6.4 Matriz de Confusión – Clasificador

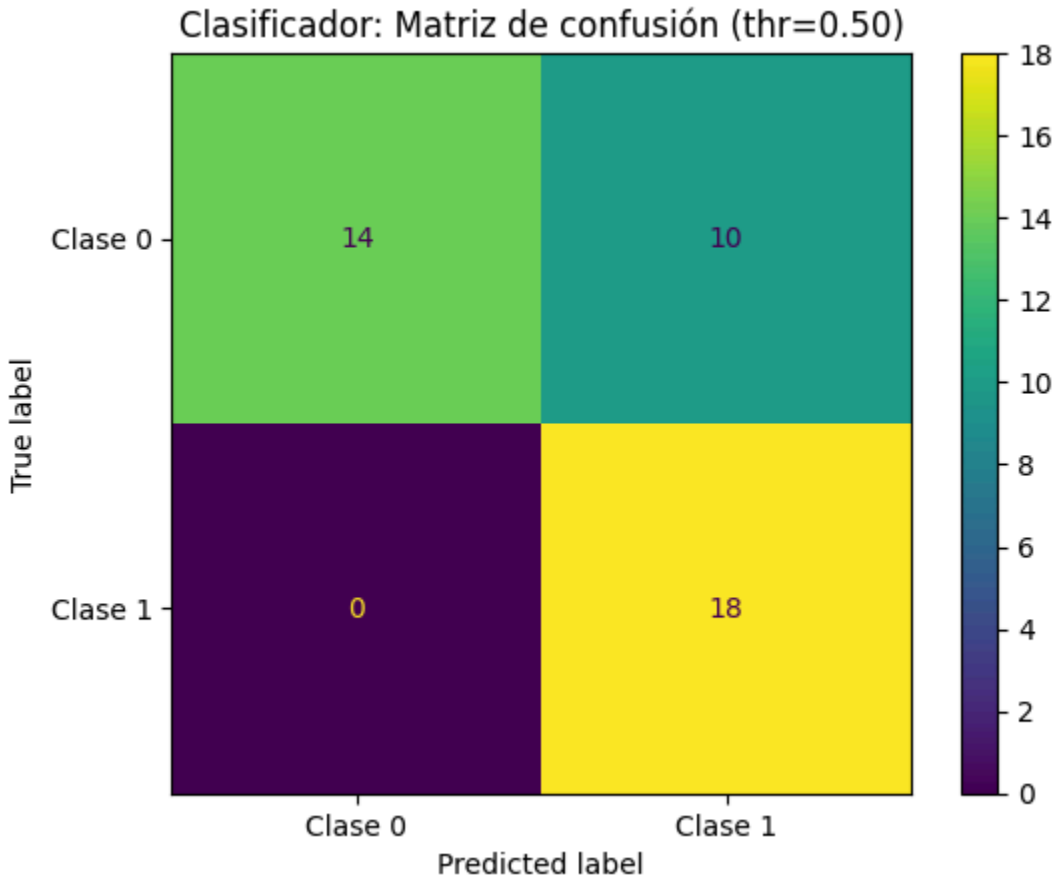

La matriz de confusión muestra un desempeño sólido en la Clase 1, con 18 verdaderos positivos y ausencia de falsos negativos.

Sin embargo, en la Clase 0 se observa cierta tasa de falsos positivos (10 casos), lo cual sugiere una ligera tendencia del modelo a sobredetectar esta categoría.

El balance general indica buena sensibilidad para la clase positiva, aunque existe margen de mejora en la especificidad.

6.5 Curva ROC

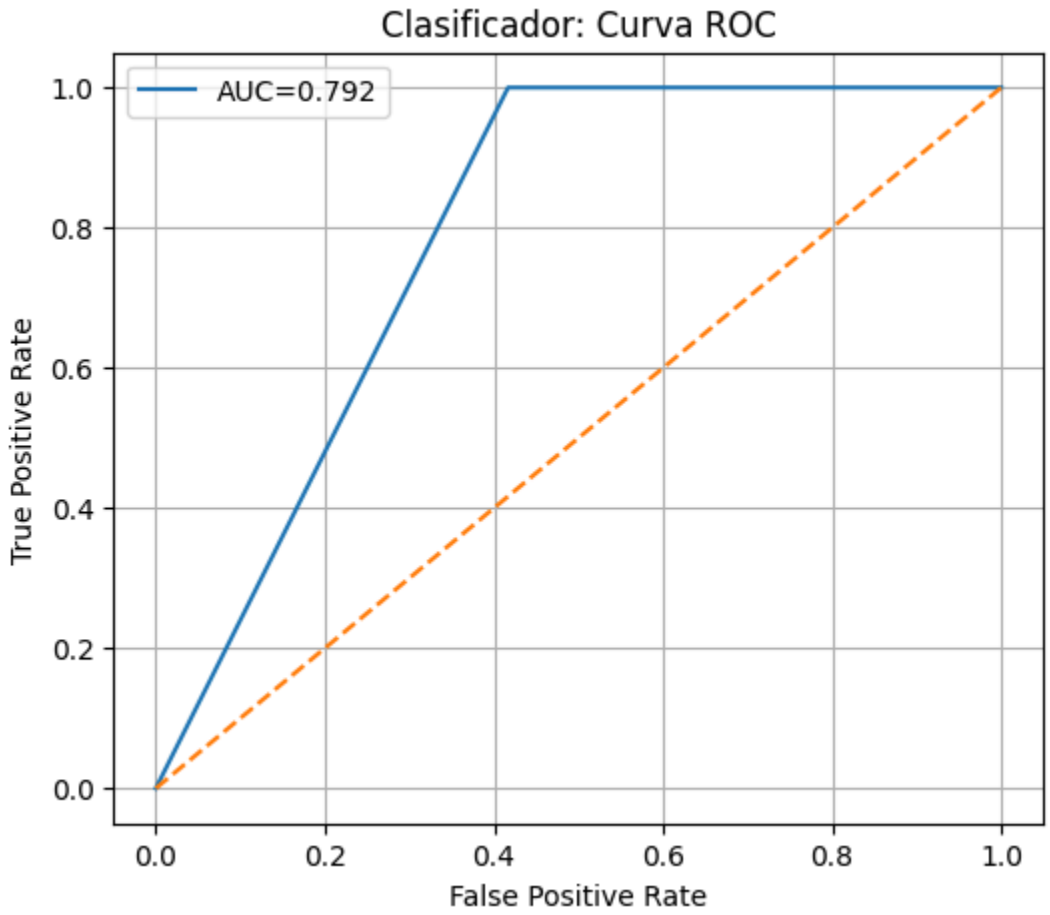

La curva ROC presenta un área bajo la curva (AUC) de 0.792, lo cual indica una capacidad discriminativa aceptable del clasificador.

El modelo supera significativamente el desempeño aleatorio (línea diagonal), aunque aún existe espacio para mejorar la separación entre clases.

Este resultado es consistente con la matriz de confusión, donde se observa buen recall pero cierta imprecisión en una de las clases.

7. Módulo Auxiliar de Clasificación Contextual

Se mantiene el modelo EfficientNet-B0 como módulo complementario de clasificación de vitrina/refrigerador, el cual opera posterior al proceso geométrico.

Este módulo incorpora umbrales diferenciados y categoría UNKNOWN, priorizando la confiabilidad sobre la cobertura total.

Sin embargo, no constituye el eje central del modelo final, sino una capa adicional de validación contextual.

El módulo de clasificación contextual fue evaluado sobre un dataset de 26 imágenes, utilizando validación cruzada debido al tamaño reducido del conjunto. Aunque no constituye el eje central del sistema, contribuye como capa adicional de validación semántica.

8. Conclusión

La implementación de estrategias de ensamble permitió incrementar la estabilidad geométrica del sistema bajo un escenario de datos limitados, mitigando la variabilidad inherente a modelos individuales entrenados sobre un conjunto reducido de imágenes.

Los resultados obtenidos demuestran que la combinación ponderada de modelos YOLOv8-pose logra un error geométrico promedio inferior al 1% en escala normalizada, manteniendo cobertura completa y consistencia estructural en la rectificación de anaqueles fríos.

Si bien el tamaño del dataset limita la capacidad de generalización estadística a gran escala, el modelo seleccionado evidencia robustez práctica bajo distintos umbrales de tolerancia espacial, lo cual lo hace viable para implementación en escenarios industriales controlados.

El sistema final equilibra precisión, estabilidad y costo computacional, cumpliendo con los objetivos técnicos y operativos planteados en el proyecto integrador.